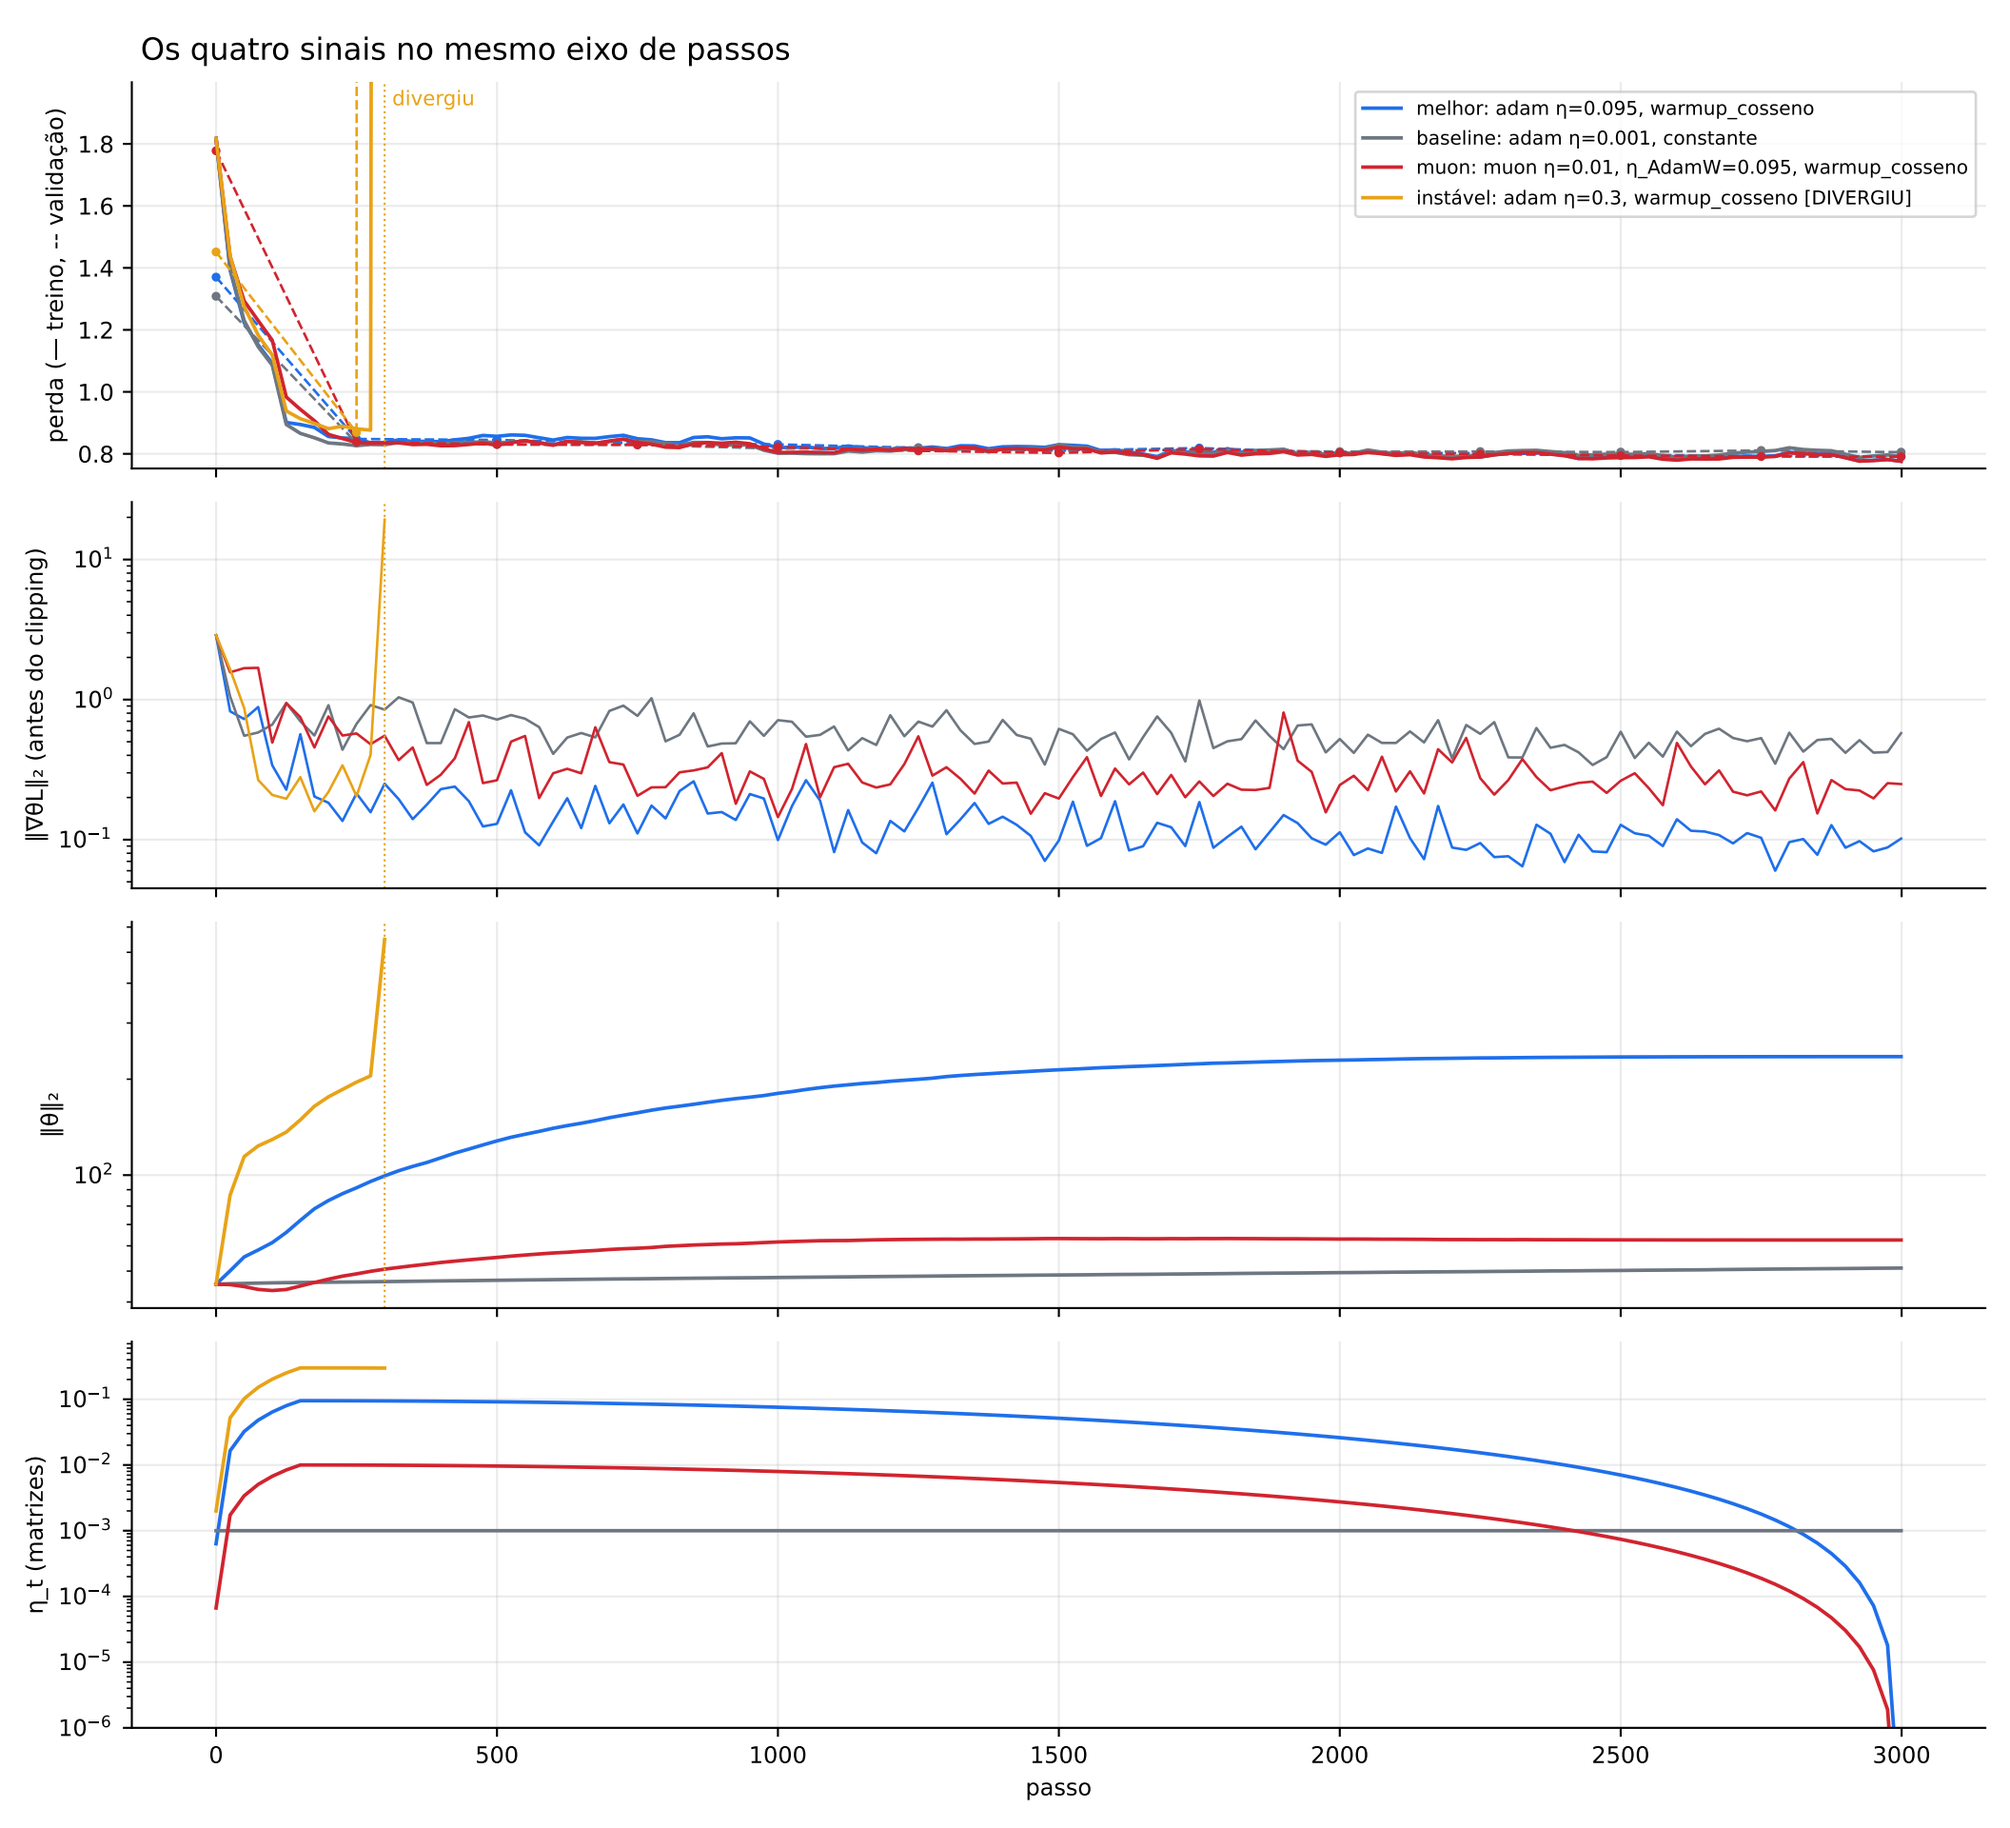
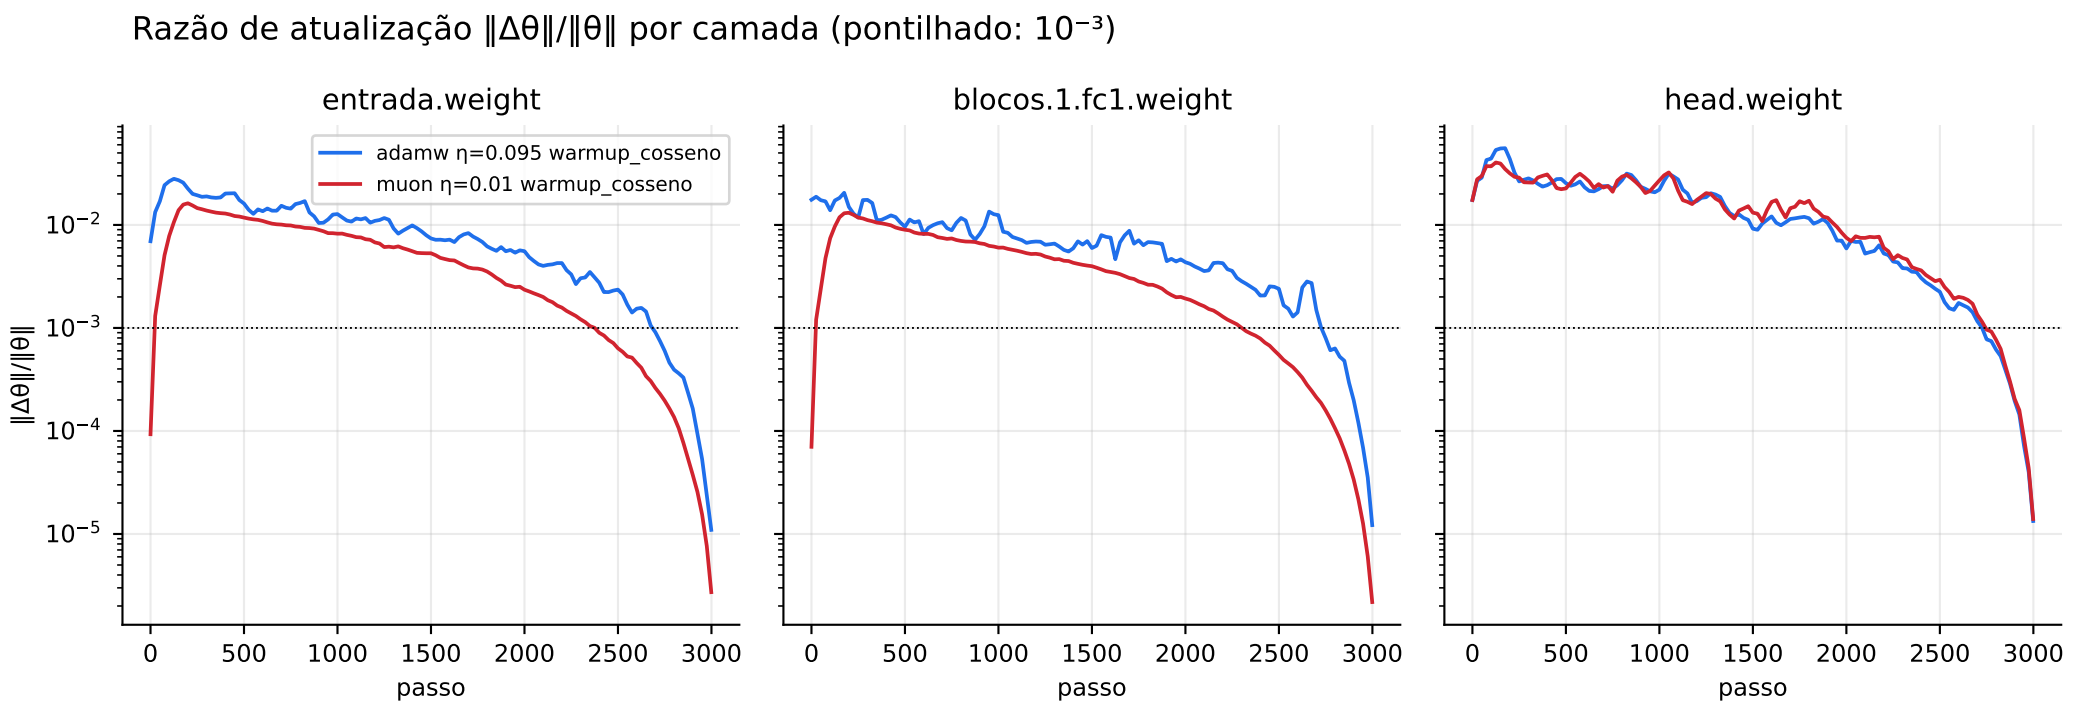
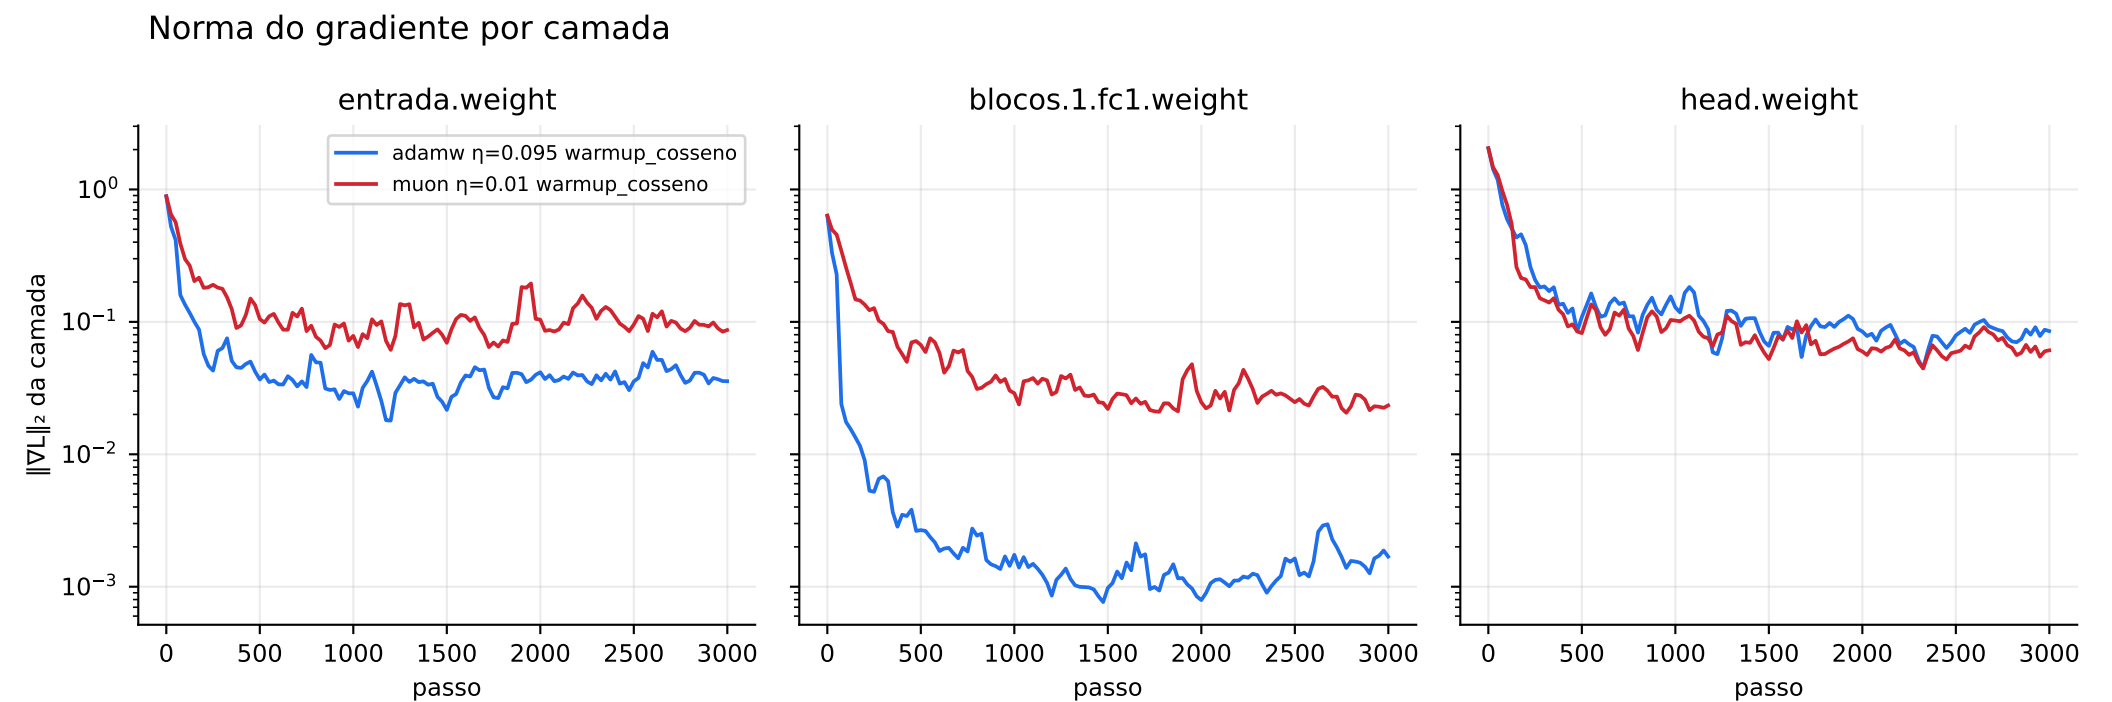
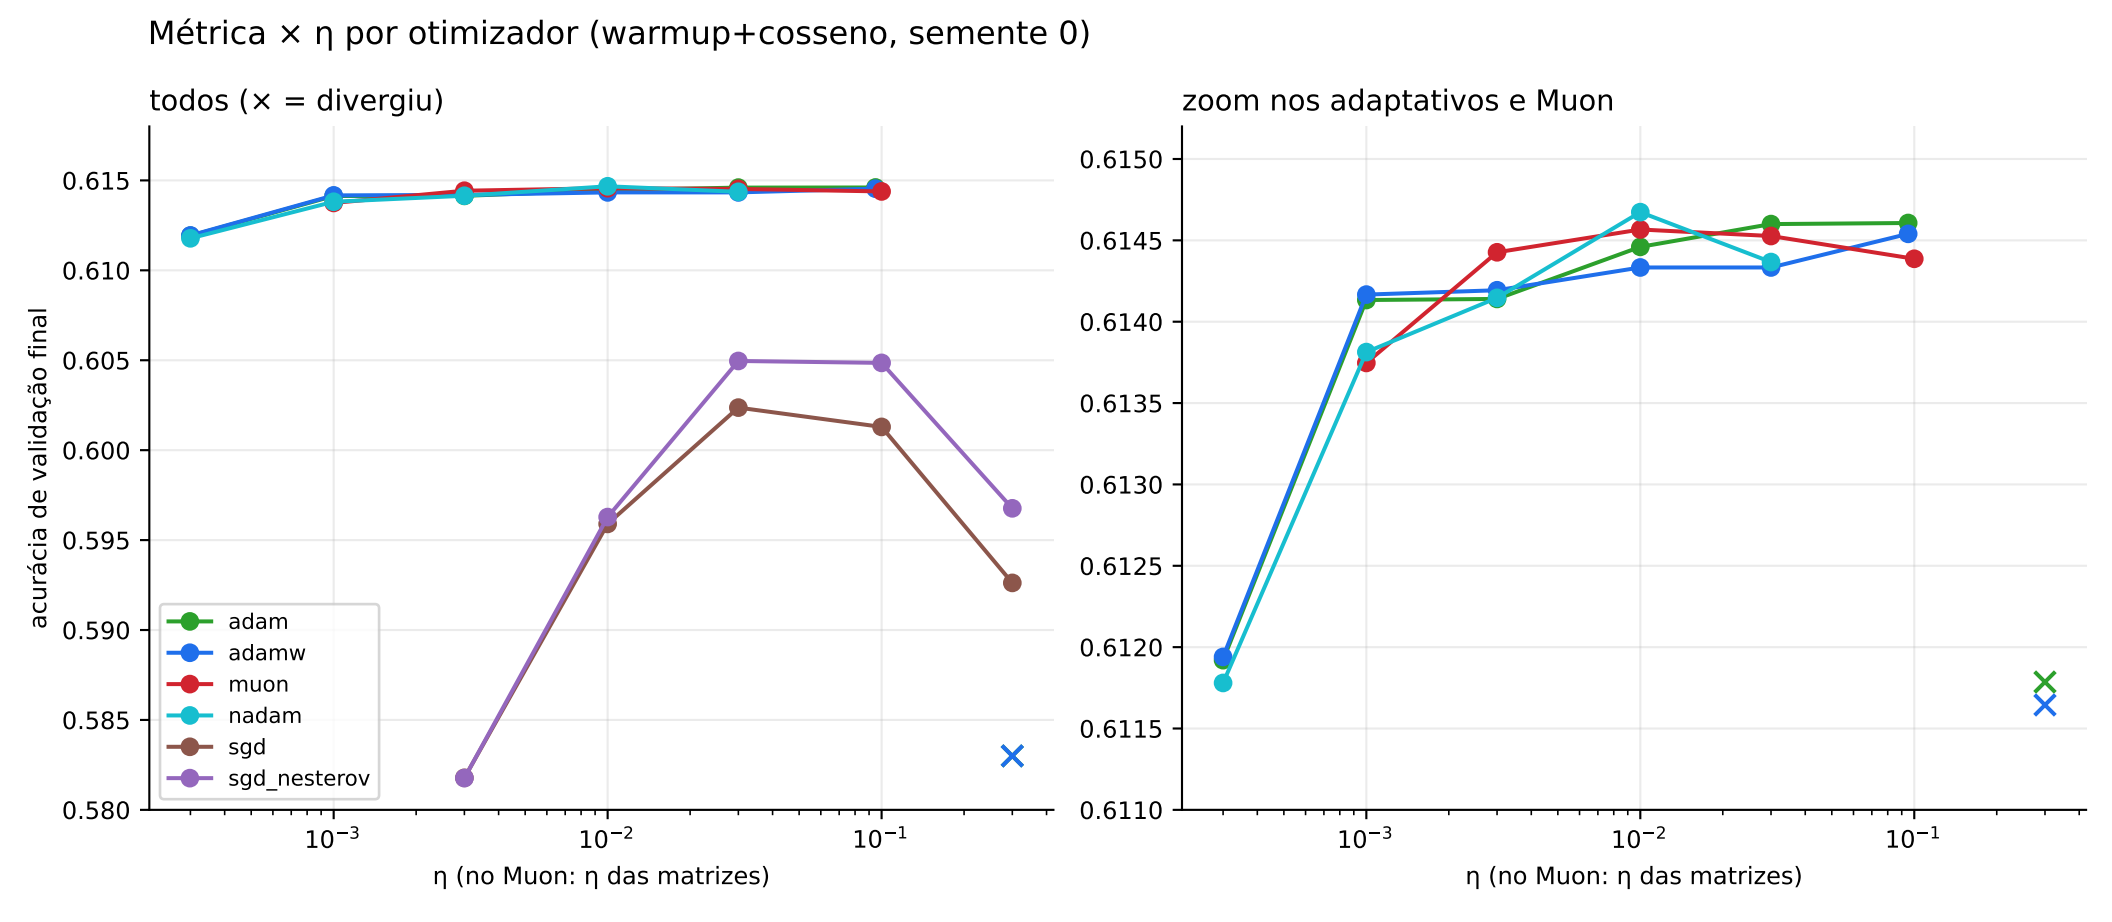
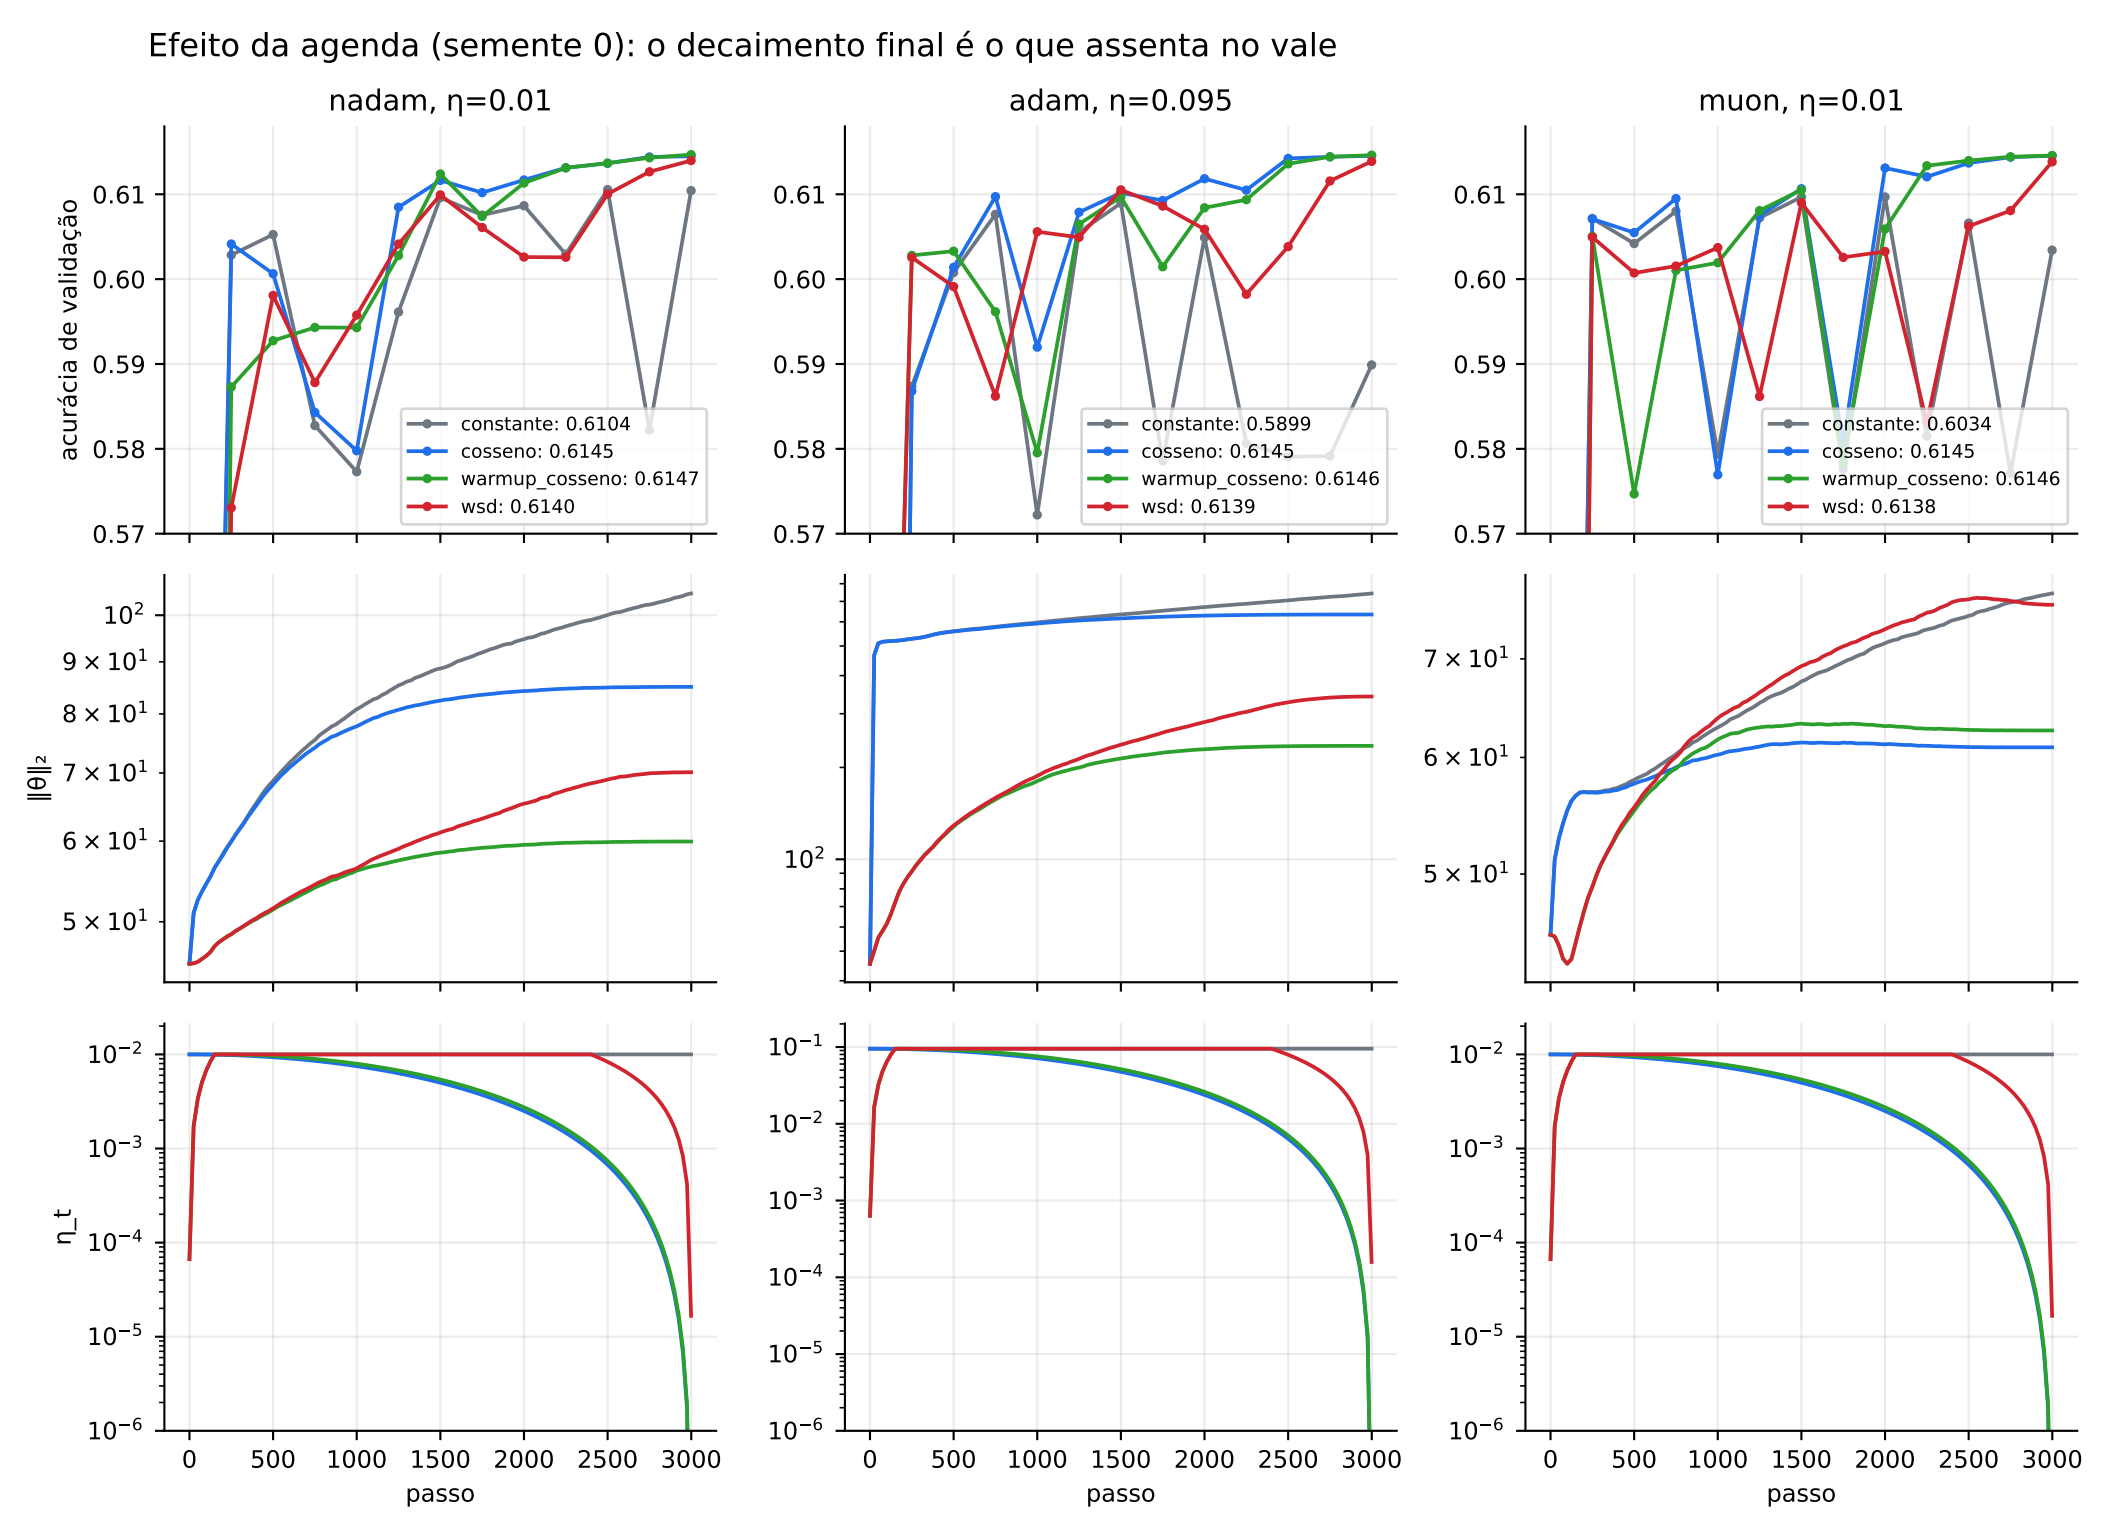

Os quatro sinais no mesmo eixo de passos
divergiu
melhor: adam η=0.095, warmup_cosseno
baseline: adam η=0.001, constante
muon: muon η=0.01, η_AdamW=0.095, warmup_cosseno
instável: adam η=0.3, warmup_cosseno [DIVERGIU]
perda (— treino, -- validação)
‖∇θL‖₂ (antes do clipping)
‖θ‖₂
η_t (matrizes)
passo


Razão de atualização ‖Δθ‖/‖θ‖ por camada (pontilhado: 10⁻³)
entrada.weight
blocos.1.fc1.weight
head.weight
adamw η=0.095 warmup_cosseno
muon η=0.01 warmup_cosseno
‖Δθ‖/‖θ‖
10⁻²
10⁻³
10⁻⁴
10⁻⁵
0
500
1000
1500
2000
2500
3000
passo


Norma do gradiente por camada
entrada.weight
blocos.1.fc1.weight
head.weight
adamw η=0.095 warmup_cosseno
muon η=0.01 warmup_cosseno
‖∇L‖₂ da camada
10^{0}
10^{-1}
10^{-2}
10^{-3}
0
500
1000
1500
2000
2500
3000
passo


Métrica × η por otimizador (warmup+cosseno, semente 0)
todos (× = divergiu)
zoom nos adaptativos e Muon
acurácia de validação final
η (no Muon: η das matrizes)
η (no Muon: η das matrizes)
adam
adamw
muon
nadam
sgd
sgd_nesterov


Efeito da agenda (semente 0): o decaimento final é o que assenta no vale
nadam, η=0.01
adam, η=0.095
muon, η=0.01
acurácia de validação
constante: 0.6104
cosseno: 0.6145
warmup_cosseno: 0.6147
wsd: 0.6140
constante: 0.5899
cosseno: 0.6145
warmup_cosseno: 0.6146
wsd: 0.6139
constante: 0.6034
cosseno: 0.6145
warmup_cosseno: 0.6146
wsd: 0.6138
‖θ‖₂
η_t
passo

Confirmação com 3 sementes

etapa	otimizador	η	agenda	val_acc média	desvio	sementes
confirmacao	adam	0.095	warmup_cosseno	0.6146	0.0001	3
confirmacao	muon	0.01	warmup_cosseno	0.6145	0.0000	3
confirmacao	nadam	0.01	warmup_cosseno	0.6144	0.0002	3
baseline	adam	0.001	constante	0.6097	0.0010	3